

Филиал Московского Государственного
Университета имени М.В. Ломоносова в городе
Баку

КУРСОВАЯ РАБОТА

на тему:

«Механизмы преобразования
естественной речи в заданные
шаблоны»

Выполнил:

студент группы 223

Казимов Сеймур Заур оглу

Научный руководитель м.н.с.

Сиротич Богдан Михайлович

Баку - 2026

Содержание

1	Введение	2
1.1	Описание задачи	2
1.2	История возникновения данной задачи	3

1 Введение

1.1 Описание задачи

В этой курсовой разрабатывался способ, который автоматически переводит устную математическую речь в структурированный синтаксис LaTeX. Традиционные системы распознавания голоса обычно хорошо работают с повседневными разговорами и обычным текстом, но с точным научным текстом справляются с трудом. Это связано с тем, что озвучивание формул включает сложные термины, неоднозначность в значении и сложную структуру — например, пределы, кратные интегралы, вложенные индексы и сложные дроби. Поэтому для правильной обработки нужен не простой пословный перевод аудио в текст, а более комплексный подход, который включает семантический анализ и логическое понимание услышанного.

Важность этой разработки связана с особенностями обучения на технических специальностях. Во время лекций студентам приходится одновременно разбираться в сложном материале и точно записывать сложные математические формулы. Часто из-за этого приходится выбирать между пониманием и записыванием конспекта. Автоматизация поможет слушателям сосредоточиться на понимании темы, пока программа возьмёт на себя ведение конспекта.

Основная задача программы — создать инструмент, который принимает аудиозапись с математическими выражениями и выдаёт правильно сформатированный код LaTeX. Итоговый документ должен точно отражать структуру, как если бы его писал студент в тетради. Для этого создаётся сложная система, которая включает:

- Первичную акустическую транскрибацию аудиосигнала в сырой текст.
- Интеллектуальный парсинг транскрибированного текста для выявления математических конструкций и связей между ними.
- Преобразование распознанных логических блоков в команды разметки и финальную сборку готового TeX-шаблона.

1.2 История возникновения данной задачи

Задача преобразования естественной речи в заданные шаблоны (в частности, в структурированный LaTeX-код математических выражений) является логическим развитием технологии автоматического распознавания речи (Automatic Speech Recognition, ASR). История ASR насчитывает более 70 лет и прошла путь от примитивных устройств, способных распознавать отдельные цифры, до современных систем, которые не только транскрибируют речь, но и преобразуют её в формализованные шаблоны с учётом семантики и контекста.

Начало исследований в области ASR относится к 1950-м годам. Первое реальное устройство появилось в 1952 году в лабораториях Bell Laboratories. Система «Audrey» (Automatic Digit Recognizer) была способна распознавать цифры от 0 до 9, произнесённые одним диктором. Она работала на основе анализа энергии в определённых частотных диапазонах (формантах) и требовала предварительной настройки под голос конкретного человека. Хотя «Audrey» была крайне ограниченной, она доказала принципиальную возможность машинного понимания речи.

В 1960-х годах прогресс продолжился. В 1962 году компания IBM представила на Всемирной выставке в Сиэтле устройство «Shoebox», которое распознавало уже 16 английских слов, включая цифры и простые арифметические команды («плюс», «минус», «итого»). «Shoebox» мог выполнять элементарные математические операции по голосовой команде, что стало первым шагом к специализированному распознаванию технической речи. В том же десятилетии появились первые эксперименты с непрерывной речью (без пауз между словами), а советские исследователи разработали алгоритм динамического временного искажения (Dynamic Time Warping, DTW), который позволял работать со словарём до 200 слов.

Настоящий прорыв произошёл в 1970-х годах благодаря государственному финансированию. В 1971–1976 годах Агентство перспективных исследовательских проектов Министерства обороны США (DARPA) запустило программу Speech Understanding Research (SUR). В рамках проекта были созданы системы Harpy (Carnegie Mellon University) и Hearsay, способные распознавать до

1000 слов в непрерывной речи. Harpy стала одной из первых систем, продемонстрировавших практическую применимость ASR.

В 1980-х годах доминирующей технологией стали скрытые марковские модели (Hidden Markov Models, HMM). Они позволили перейти от простого сравнения шаблонов к вероятностному моделированию речи. Ключевую роль сыграли работы Фреда Джелинека в IBM (система Tangora с словарём 20 000 слов) и команды CMU (Sphinx). HMM заменили DTW и стали основой всех промышленных систем до конца 2000-х годов.

Коммерциализация ASR началась в 1990-х. В 1990 году вышла первая потребительская программа Dragon Dictate, а в 1997 году — Dragon NaturallySpeaking, которая поддерживала непрерывную речь со скоростью до 100 слов в минуту. Эти системы уже могли использоваться для диктовки текстов, в том числе технических. В 1992 году AT&T запустила первую голосовую систему маршрутизации звонков.

В 2000-х и начале 2010-х годов ASR активно применялась в телефонии, диктовке медицинских заключений и офисных приложениях. Однако точность оставалась недостаточной для сложных доменов, таких как математика. Требовалась не просто транскрипция, а преобразование речи в формализованные шаблоны (LaTeX, MathML и т.д.).

Революция произошла в 2010-х с приходом глубокого обучения. В 2014 году Baidu представила Deep Speech — первую end-to-end модель на основе RNN. В 2015 году Google внедрила Listen, Attend and Spell (LAS), а в 2017 году — трансформеры. Эти технологии резко повысили точность и позволили работать с шумной речью и разными акцентами. В 2022 году OpenAI выпустила модель Whisper, которая стала стандартом для многих современных ASR-систем.

Таким образом, с появлением модели Whisper в 2022 году технология автоматического распознавания речи достигла уровня, позволяющего эффективно решать задачи не только транскрипции, но и преобразования естественной речи в строго заданные шаблоны. Однако, несмотря на первые попытки решения именно математической диктовки ещё в 2009 году (система TalkMaths) и появление новых датасетов и моделей на базе Whisper и LLM в 2024–2025 годах, полноценные практические реализации остаются редкостью. Большинство

существующих решений либо устарели, либо представляют собой научные прототипы без открытого кода и удобной модульной архитектуры. В связи с этим разработка полноценной системы, преобразующей аудиофайл с математической диктовкой в готовый LaTeX-код с чётко выделенными модулями распознавания, обработки выражений и стилизации, является актуальной и практически значимой задачей.