

Филиал Московского Государственного
Университета имени М.В. Ломоносова в городе
Баку

КУРСОВАЯ РАБОТА

на тему:

«Механизмы преобразования
естественной речи в заданные
шаблоны»

Выполнил:
студент группы 223
Казимов Сеймур Заур оглу

Научный руководитель м.н.с.
Сиротич Богдан Михайлович

Баку - 2026

Содержание

1	Введение	2
1.1	Основные понятия и определения	2
1.2	Описание задачи	2
1.3	История возникновения данной задачи	3
1.4	Железо на котором реализовывалась программа	5
2	Проектирование системы	7
2.1	Выбор технологий и инструментов	7

1 Введение

1.1 Основные понятия и определения

Автоматическое распознавание речи (ASR, Automatic Speech Recognition)

технология, позволяющая компьютеру преобразовывать речевой аудиосигнал в текстовое представление.

Скрытая марковская модель (HMM, Hidden Markov Model) — вероятностная модель, используемая для описания временных последовательностей, в которой состояния системы не наблюдаются напрямую.

LaTeX — система компьютерной вёрстки, широко применяемая для оформления научных и технических документов, особенно содержащих математические формулы.

Промпт (англ. prompt) — это формализованный входной сигнал или текстовая инструкция, подаваемая на вход языковой модели (LLM) для задания контекста и управления процессом генерации выходной последовательности.

Транскрибация — процесс перевода речевого сигнала в письменный текст.

1.2 Описание задачи

В этой курсовой разрабатывался способ, который автоматически переводит устную математическую речь в структурированный синтаксис LaTeX. Традиционные системы распознавания голоса обычно хорошо работают с повседневными разговорами и обычным текстом, но с точным научным текстом справляются с трудом. Это связано с тем, что озвучивание формул включает сложные термины, неоднозначность в значении и сложную структуру — например, пределы, кратные интегралы, вложенные индексы и сложные дроби. Поэтому для правильной обработки нужен не простой пословный перевод аудио в текст, а более комплексный подход, который включает семантический анализ и логическое понимание услышанного.

Важность этой разработки связана с особенностями обучения на технических специальностях. Во время лекций студентам приходится одновременно разбираться в сложном материале и точно записывать сложные математические

формулы. Часто из-за этого приходится выбирать между пониманием и записыванием конспекта. Автоматизация поможет слушателям сосредоточиться на понимании темы, пока программа возьмёт на себя ведение конспекта.

Основная задача программы — создать инструмент, который принимает аудиозапись с математическими выражениями и выдаёт правильно сформатированный код LaTeX. Итоговый документ должен точно отражать структуру, как если бы его писал студент в тетради. Для этого создаётся сложная система, которая включает:

- Первичную акустическую транскрибацию аудиосигнала в сырой текст.
- Интеллектуальный парсинг транскрибированного текста для выявления математических конструкций и связей между ними.
- Преобразование распознанных логических блоков в команды разметки и финальную сборку готового TeX-шаблона.

1.3 История возникновения данной задачи

Задача преобразования естественной речи в заданные шаблоны (в частности, в структурированный LaTeX-код математических выражений) является логическим развитием технологии автоматического распознавания речи (Automatic Speech Recognition, ASR). История ASR насчитывает более 70 лет и прошла путь от примитивных устройств, способных распознавать отдельные цифры, до современных систем, которые не только транскрибируют речь, но и преобразуют её в формализованные шаблоны с учётом семантики и контекста.

Начало исследований в области ASR относится к 1950-м годам. Первое реальное устройство появилось в 1952 году в лабораториях Bell Laboratories. Система «Audrey» (Automatic Digit Recognizer) была способна распознавать цифры от 0 до 9, произнесённые одним диктором. Она работала на основе анализа энергии в определённых частотных диапазонах (формантах) и требовала предварительной настройки под голос конкретного человека. Хотя «Audrey» была крайне ограниченной, она доказала принципиальную возможность машинного понимания речи.

В 1960-х годах прогресс продолжился. В 1962 году компания IBM представила на Всемирной выставке в Сиэтле устройство «Shoebox», которое распознавало уже 16 английских слов, включая цифры и простые арифметические команды («плюс», «минус», «итого»). «Shoebox» мог выполнять элементарные математические операции по голосовой команде, что стало первым шагом к специализированному распознаванию технической речи. В том же десятилетии появились первые эксперименты с непрерывной речью (без пауз между словами), а советские исследователи разработали алгоритм динамического временного искажения (Dynamic Time Warping, DTW), который позволял работать со словарём до 200 слов.

Настоящий прорыв произошёл в 1970-х годах благодаря государственному финансированию. В 1971–1976 годах Агентство перспективных исследовательских проектов Министерства обороны США (DARPA) запустило программу Speech Understanding Research (SUR). В рамках проекта были созданы системы Harpy (Carnegie Mellon University) и Hearsay, способные распознавать до 1000 слов в непрерывной речи. Harpy стала одной из первых систем, продемонстрировавших практическую применимость ASR.

В 1980-х годах доминирующей технологией стали скрытые марковские модели (Hidden Markov Models, HMM). Они позволили перейти от простого сравнения шаблонов к вероятностному моделированию речи. Ключевую роль сыграли работы Фреда Джелинека в IBM (система Tangora с словарём 20 000 слов) и команды CMU (Sphinx). HMM заменили DTW и стали основой всех промышленных систем до конца 2000-х годов.

Коммерциализация ASR началась в 1990-х. В 1990 году вышла первая потребительская программа Dragon Dictate, а в 1997 году — Dragon NaturallySpeaking, которая поддерживала непрерывную речь со скоростью до 100 слов в минуту. Эти системы уже могли использоваться для диктовки текстов, в том числе технических. В 1992 году AT&T запустила первую голосовую систему маршрутизации звонков.

В 2000-х и начале 2010-х годов ASR активно применялась в телефонии, диктовке медицинских заключений и офисных приложениях. Однако точность оставалась недостаточной для сложных доменов, таких как математика. Тре-

бовалась не просто транскрипция, а преобразование речи в формализованные шаблоны (LaTeX, MathML и т.д.).

Революция произошла в 2010-х с приходом глубокого обучения. В 2014 году Baidu представила Deep Speech — первую end-to-end модель на основе RNN. В 2015 году Google внедрила Listen, Attend and Spell (LAS), а в 2017 году — трансформеры. Эти технологии резко повысили точность и позволили работать с шумной речью и разными акцентами. В 2022 году OpenAI выпустила модель Whisper, которая стала стандартом для многих современных ASR-систем.

Таким образом, с появлением модели Whisper в 2022 году технология автоматического распознавания речи достигла уровня, позволяющего эффективно решать задачи не только транскрипции, но и преобразования естественной речи в строго заданные шаблоны. Однако, несмотря на первые попытки решения именно математической диктовки ещё в 2009 году (система TalkMaths) и появление новых датасетов и моделей на базе Whisper и LLM в 2024–2025 годах, полноценные практические реализации остаются редкостью. Большинство существующих решений либо устарели, либо представляют собой научные прототипы без открытого кода и удобной модульной архитектуры. В связи с этим разработка полноценной системы, преобразующей аудиофайл с математической диктовкой в готовый LaTeX-код с чётко выделенными модулями распознавания, обработки выражений и стилизации, является актуальной и практически значимой задачей.

1.4 Железо на котором реализовывалась программа

Одним из важных факторов влияющих на реализацию программы является технические характеристики компьютера на котором запускается данная программа. Характеристики компьютера напрямую будут определять какие модели можно будет запускать с приемлимой скоростью и точностью. На более слабом железе (Например без дискретной видеокарты или с малым объёмом видеопамяти) придётся использовать более лёгкие модели для транскрибации и для выявления математических формул.

В рамках данной курсовой работы программа разрабатывалась и тестиро-

вавалась на компьютере с такими техническими характеристиками:

- Процессор: Intel(R) Core(TM) i7-14700HX
- Оперативная память: 16 ГБ
- Видеокарта: NVIDIA GeForce RTX 4060 Laptop GPU (8 ГБ VRAM)

2 Проектирование системы

2.1 Выбор технологий и инструментов

Для реализации системы преобразования естественной математической речи в структурированный LaTeX-код был выбран модульный подход, состоящий из трёх основных этапов: распознавание речи, интеллектуальная обработка текста с преобразованием в математические формулы и финальная стилистическая вёрстка. Такой конвейер (pipeline) позволяет разделить задачи по сложности и использовать наиболее подходящие инструменты для каждой из них.

На первом этапе — автоматического распознавания речи (ASR) — использовалась открытая нейросетевая модель Whisper-medium (OpenAI). Модель была запущена через библиотеку Hugging Face Transformers. Для загрузки и предобработки аудиофайла применялась библиотека librosa. Whisper-medium была выбрана благодаря хорошему качеству распознавания русской технической речи, поддержке чанкинга длинных аудиозаписей и возможности явно указывать язык (`language="russian"`). Скрипт реализации данного этапа находится в файле `whisper.py`.

На втором этапе — преобразования естественного текста в структурированный LaTeX — использовалась локальная большая языковая модель Qwen (конкретно вариант `qwen3-esper3-reasoning-coder-instruct-12b-brainstorm20x-i1` в квантизации `Q4_K_M`). Модель запускалась через сервер LM Studio с использованием OpenAI-совместимого API.

Выбор данной модели обусловлен:

- Высокой компетенцией в работе с формальными языками и LaTeX;
- Хорошим пониманием математической терминологии;
- Возможностью полностью локального запуска.

Обработка выполнялась с помощью тщательно составленного системного промпта, который строго регламентирует правила замены словесных математических конструкций на LaTeX-код, не позволяя модели переписывать исходный текст. Реализация данного модуля содержится в файле `qwen.py`.

Третий этап — стилистическое оформление LaTeX-документа — также реализован с помощью той же модели Qwen, но с другим системным промптом. Задача модуля заключается в расстановке переносов строк, выделении заголовков жирным шрифтом и логическом разделении абзацев. Данный этап реализован в файле `stilst.py` и позволяет получить аккуратный, готовый к компиляции файл `final_lecture.tex`.

Общее управление всеми этапами осуществляет главный скрипт `main.py`, который последовательно запускает модули с помощью модуля `subprocess` Python. Такой архитектурный выбор упрощает отладку, тестирование и возможную замену отдельных компонентов системы.

В качестве основного языка программирования был выбран Python 3. Для взаимодействия с языковыми моделями использовалась библиотека `openai` (в режиме совместимости с локальным сервером). Целевым форматом вывода является LaTeX с поддержкой русского языка.

Таким образом, выбранный стек технологий обеспечивает баланс между качеством распознавания и преобразования математической речи, удобством разработки и возможностью запуска на обычном персональном компьютере без зависимости от облачных сервисов.

Список литературы

- [1] Davis K.H., Biddulph R., Balashek S. Automatic recognition of spoken digits // Journal of the Acoustical Society of America. — 1952. — Vol. 24. — P. 637–642.
- [2] IBM Shoebox // HandWiki. — URL: https://handwiki.org/wiki/Software:IBM_Shoebox .
- [3] Reddy D.R. et al. A Historical Perspective of Speech Recognition // Communications of the ACM. — URL: <https://cacm.acm.org/research/a-historical-perspective-of-speech-recognition/> .
- [4] Hannun A. et al. Deep Speech: Scaling up end-to-end speech recognition // arXiv preprint. — 2014. — arXiv:1412.5567. — URL: <https://arxiv.org/abs/1412.5567>.
- [5] Chan W. et al. Listen, Attend and Spell // arXiv preprint. — 2015. — arXiv:1508.01211. — URL: <https://arxiv.org/abs/1508.01211>.
- [6] Vaswani A. et al. Attention Is All You Need // Advances in Neural Information Processing Systems (NeurIPS). — 2017. — Vol. 30.
- [7] Radford A. et al. Robust Speech Recognition via Large-Scale Weak Supervision // OpenAI Technical Report. — 2022. — URL: <https://openai.com/research/whisper>.
- [8] Audrey, Alexa, HAL and More // Computer History Museum. — URL: <https://computerhistory.org/blog/audrey-alexa-hal-and-more/> .